Czyszczenie oraz uzupełnianie brakujących danych w Excelu

	A	B	C	D	E	F	G	H
1	Column1	Column2	Column3	Column4	Column5	Column6	Column7	Column8
2	Transaction ID	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
3	TXN_1961373	Coffee	2	2.0	4.0	Credit Card	Takeaway	2023-09-08
4	TXN_4977031	Cake	4	3.0	12.0	Cash	In-store	2023-05-16
5	TXN_4271903	Cookie	4	1.0	ERROR	Credit Card	In-store	2023-07-19
6	TXN_7034554	Salad	2	5.0	10.0	UNKNOWN	UNKNOWN	2023-04-27
7	TXN_3160411	Coffee	2	2.0	4.0	Digital Wallet	In-store	2023-06-11
8	TXN_2602893	Smoothie	5	4.0	20.0	Credit Card		2023-03-31
9	TXN_4433211	UNKNOWN	3	3.0	9.0	ERROR	Takeaway	2023-10-06
10	TXN_6699534	Sandwich	4	4.0	16.0	Cash	UNKNOWN	2023-10-28
11	TXN_4717867		5	3.0	15.0		Takeaway	2023-07-28
12	TXN_2064365	Sandwich	5	4.0	20.0		In-store	2023-12-31
13	TXN_2548360	Salad	5	5.0	25.0	Cash	Takeaway	2023-11-07
14	TXN_3051279	Sandwich	2	4.0	8.0	Credit Card	Takeaway	ERROR

Na przykładowych danych widać, że są one nieuporządkowane, znajduje się tu wiele pustych pól oraz błędów. Dodatkowo dane liczbowe są zapisane w formacie liczby dziesiętnej Zaczynam od zmiany danych liczbowych tak, aby nie zawierały końcowego „.0”. W tym celu wchodzę w **Dane → Tekst jako kolumny → Dalej**

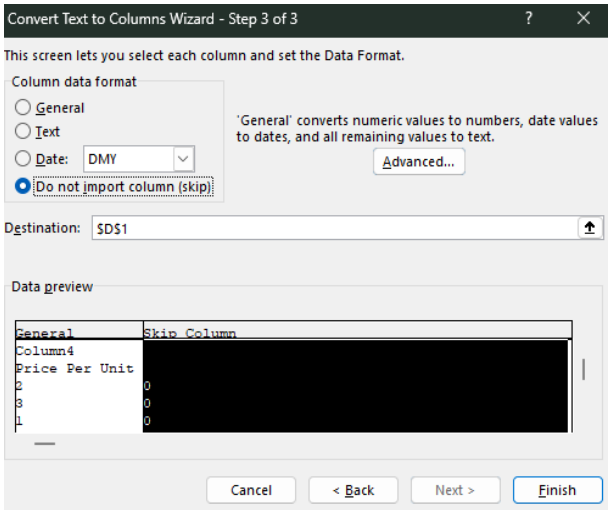

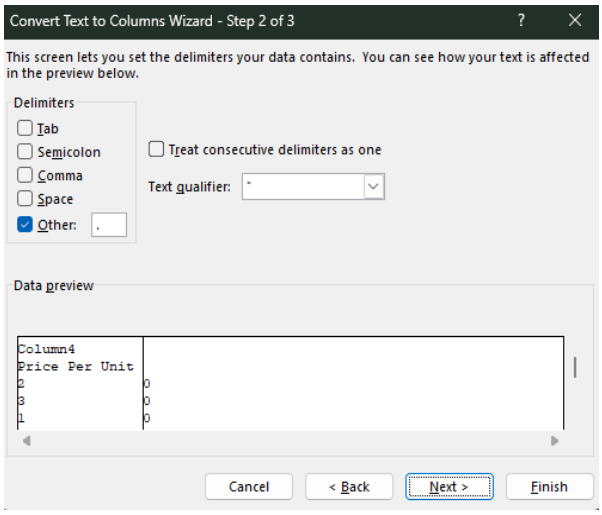

Następnie w sekcji **Delimiter** zaznaczam **Other** i wpisuję „.” Klikam **Dalej**, a w **Column Data Format** zaznaczam kolumnę, w której znajdują się zera, i wybieram opcję **Do not import column (Skip)**. Na końcu klikam **Finish**.

	A	B	C	D	E	F	G	H
1	Transaction	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
2	TXN_1961373	Coffee	2	2	4	Credit Card	Takeaway	2023-09-08
3	TXN_4977031	Cake	4	3	12	Cash	In-store	2023-05-16
4	TXN_4271903	Cookie	4	1	ERROR	Credit Card	In-store	2023-07-19
5	TXN_7034554	Salad	2	5	10	UNKNOWN	UNKNOWN	2023-04-27
6	TXN_3160411	Coffee	2	2	4	Digital Wallet	In-store	2023-06-11
7	TXN_2602893	Smoothie	5	4	20	Credit Card		2023-03-31
8	TXN_4433211	UNKNOWN	3	3	9	ERROR	Takeaway	2023-10-06
9	TXN_6699534	Sandwich	4	4	16	Cash	UNKNOWN	2023-10-28
10	TXN_4717867		5	3	15		Takeaway	2023-07-28
11	TXN_2064365	Sandwich	5	4	20		In-store	2023-12-31
12	TXN_2548360	Salad	5	5	25	Cash	Takeaway	2023-11-07
13	TXN_3051279	Sandwich	2	4	8	Credit Card	Takeaway	ERROR

Poprawiam również nazwy kolumn. Zamieniam miejscami wiersze **1 i 2**, a następnie usuwam **wiersz 2**. Dzięki temu dane oraz nazwy kolumn są już uporządkowane.

Następnie zajmuję się wypełnianiem pustych pól oraz błędów w kolumnach **Quantity**, **Price Per Unit** oraz **Total Spent**.
Brakujące wartości w kolumnie **Total Spent** obliczam za pomocą formuły **C2*D2**.

PRZED I PO

E	I
Total Spent	Column1
4	4
12	12
ERROR	4
10	10
4	4
20	20
9	9
16	16
15	15
20	20
25	25
8	8
8	8
5	5
3	2
15	15
4	4
6	6
15	15
12	12
20	#VALUE!
16	16
12	12
8	8
20	20
	12
5	5
12	12
20	20
12	12
10	10
ERROR	2

Następnie musimy wkleić te dane w nasza pierwotną kolumnę, ale jak widać w mojej tymczasowej kolumnie mamy błąd **#VALUE!** mimo że w oryginalnej kolumnie znajdują się wartości. Wynika to z tego, że podczas obliczania **C2*D2** (czyli **Quantity × Price Per Unit**) w jednej z tych kolumn brakowało danych. Aby szybko zaznaczyć wszystkie błędy, używam skrótu **CTRL + G**, który otwiera okno **Go To**. Następnie wybieram **Special**, przechodzę do **Go To Special** i zaznaczam **Formulas**, a potem **Logicals** oraz **Errors**, po czym klikam **OK**.

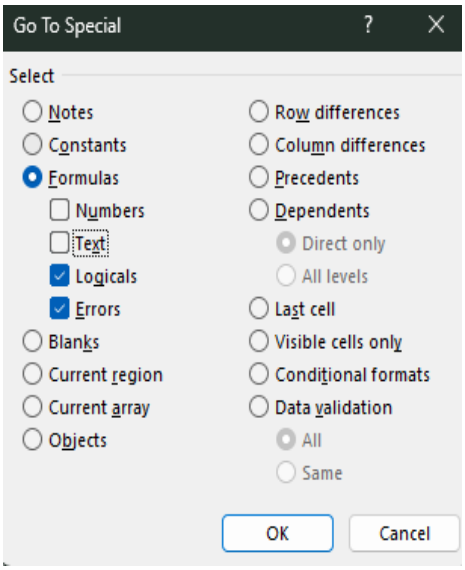

W ten sposób wszystkie błędy w obliczeniach zostają zaznaczone. Klikam w pasek formuły, usuwam znajdującą się tam zawartość i naciskam **CTRL + ENTER.**

I	I
Column1	Column1
4	4
12	12
4	4
10	10
4	4
20	20
9	9
16	16
15	15
20	20
25	25
8	8
8	8
5	5
2	2
15	15
4	4
6	6
15	15
12	12
#VALUE!	
16	16
12	12
8	8

PRZED I PO

Następnie ponownie korzystam z **Go To Special**, tym razem zaznaczając tylko **puste pola**. W pasku formuły wpisuję **=E2**, aby odwołać się do wartości z oryginalnej kolumny, i ponownie używam **CTRL + ENTER**. Dzięki temu wartości z kolumny **Total Spent** zostają wstawione do pustych pól w kolumnie pomocniczej.

W ten sposób uzyskuję komplet wartości. Ten sam proces powtarzam dla dwóch pozostałych kolumn, z tą różnicą, że zmieniam formuły.

- **Price Per Unit** obliczam za pomocą formuły **=E2/C2**
- **Quantity** obliczam za pomocą formuły **=E2/D2**

	A	B	C	D	E	F	G	H	I
1	Transaction	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date	Column
2	TXN_1961373	Coffee	2	2	4	Credit Card	Takeaway	2023-09-08	=E2/C2

Tym sposobem mamy obliczone wszystkie 3 kolumny

C	D	E
Quantity	Price Per Unit	Total Spent
2	2	4
4	3	12
4	1	ERROR
2	5	10
2	2	4
5	4	20
3	3	9
4	4	16
5	3	15
5	4	20
5	5	25
2	4	8
2	4	8
5	1	5
2	1	3
3	5	15
1	4	4
2	3	6
5	3	15
4	3	12
ERROR	4	20
4	4	16
3	4	12
2	4	8
5	4	20
3	4	
5	1	5
4	3	12
5	4	20
4	3	12
5	2	10
2	1	ERROR
4	4	16
5	1	5
2	4	8
1	4	4

PRZED

C	D	E
Quantity	Price Per Unit	Total Spent
2	2	4
4	3	12
4	1	4
2	5	10
2	2	4
5	4	20
3	3	9
4	4	16
5	3	15
5	4	20
5	5	25
2	4	8
2	4	8
5	1	5
2	1	2
3	5	15
1	4	4
2	3	6
5	3	15
4	3	12
5	4	20
4	4	16
3	4	12
2	4	8
5	4	20
3	4	12
5	1	5
4	3	12
5	4	20
4	3	12
5	2	10
2	1	2
4	4	16
5	1	5
2	4	8
1	4	4

PO

Teraz musimy zająć się pozostałymi kolumnami

	A	B	C	D	E	F	G	H
1	Transaction	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
2	TXN_1961373	Coffee	2	2	4	Credit Card	Takeaway	2023-09-08
3	TXN_4977031	Cake	4	3	12	Cash	In-store	2023-05-16
4	TXN_4271903	Cookie	4	1	4	Credit Card	In-store	2023-07-19
5	TXN_7034554	Salad	2	5	10	UNKNOWN	UNKNOWN	2023-04-27
6	TXN_3160411	Coffee	2	2	4	Digital Wallet	In-store	2023-06-11
7	TXN_2602893	Smoothie	5	4	20	Credit Card		2023-03-31
8	TXN_4433211	UNKNOWN	3	3	9	ERROR	Takeaway	2023-10-06
9	TXN_6699534	Sandwich	4	4	16	Cash	UNKNOWN	2023-10-28
10	TXN_4717867		5	3	15		Takeaway	2023-07-28
11	TXN_2064365	Sandwich	5	4	20		In-store	2023-12-31
12	TXN_2548360	Salad	5	5	25	Cash	Takeaway	2023-11-07
13	TXN_3051279	Sandwich	2	4	8	Credit Card	Takeaway	ERROR
14	TXN_7619095	Sandwich	2	4	8	Cash	In-store	2023-05-03
15	TXN_9437049	Cookie	5	1	5		Takeaway	2023-06-01
16	TXN_8915701	ERROR	2	1	3		In-store	2023-03-21
17	TXN_2847255	Salad	3	5	15	Credit Card	In-store	2023-11-15
18	TXN_3765707	Sandwich	1	4	4			2023-06-10

W pomocniczej tabeli **PivotTable** sprawdzam, czy dane wykazują jakąś zależność.

Count of Transaction ID	Column Labels											
Row Labels	0	1	1,333333333	1,4	1,5	2	3	4	5	ERROR	UNKNOWN	Grand Total
Cake	21						1116			2		1139
Coffee	19					1144					2	1165
Cookie	25	1063								2	2	1092
ERROR	7	72			2	31	78	62	39	1		292
Juice	17						1154					1171
Salad	16								1131		1	1148
Sandwich	18							1111		1	1	1131
Smoothie	24							1068		2	2	1096
Tea	20	1030		7	12	15				2	3	1089
(blank)	15	157			3	94	162	159	85	1	1	677
Grand Total	182	2322		7	12	20	1269	2510	2400	1255	11	12	10000

Jak widać tylko *coffee* ma cenę 2, tak samo *salad* ma tylko cenę 5. Wiedząc to, wypełniamy wszystkie puste pola w kolumnie *item* produktem **coffee** tam, gdzie cena wynosi 2. Analogicznie postępujemy z **salad**, uzupełniając pola przy cenie 5. Robimy to za pomocą tej formuły:

```
=IF(OR(ISBLANK(B2); ISERROR(B2)); IF(D2=2; "Coffee"); B2)
```

W pozostałych pustych polach wpisujemy **UNKNOWN**, ponieważ dla niektórych cen występuje więcej niż jeden możliwy produkt. Przykładowo cena **1** pojawia się zarówno przy **cookie** (1063 razy), jak i **tea** (1030 razy). Różnica w liczbie wystąpień jest bardzo mała, dlatego nie można jednoznacznie określić, który produkt odpowiada brakującym rekordom. W celu uniknięcia błędnej imputacji dane te zostają oznaczone jako **UNKNOWN**.

Następnie zajmuję się kolumną **Payment**. W pomocniczej tabeli **PivotTable** sprawdzam, czy dane wykazują jakąś zależność, na przykład względem lokalizacji.

Count of Transaction ID	Column Labels					
Row Labels	ERROR	In-store	Takeaway	UNKNOWN	(blank)	Grand Total
⊞Cash	87	702	664	74	731	2258
⊞Credit Card	82	681	669	84	757	2273
⊞Digital Wallet	78	695	744	71	703	2291
⊞ERROR	12	91	75	10	118	306
⊞UNKNOWN	7	78	88	12	108	293
⊞(blank)	92	770	782	87	848	2579
Grand Total	358	3017	3022	338	3265	10000

Okazuje się jednak, że podobnie jak w przypadku **Price**, wartości różnią się bardzo nieznacznie, dlatego trudno określić jednoznaczną zależność.

Mam więc dwie możliwości:

- Wpisać w kolumnie **Payment** wartość **„Unknown”**,
- Uzupełnić dane losowo.

W tym przypadku wybieram drugą opcję i uzupełniam brakujące wartości losowo za pomocą odpowiedniej formuły.

```
=IF(OR(ISBLANK(F2); ISERROR(F2)); CHOOSE(RANDBETWEEN(1;3); "Cash"; "Card"; "Online"); F2)
```

Podobna sytuacja występuje w kolumnie **Location**, dlatego również tutaj uzupełniam dane losowo.

```
=IF(OR(ISBLANK(G2); ISERROR(G2)); CHOOSE(RANDBETWEEN(1;2); "In-store"; "Takeaway"); G2)
```

W przypadku kolumny **Transaction Date** stosuję inne rozwiązanie używam formuły, która zakłada, że data jest taka sama jak w poprzedniej transakcji.

```
=IF(OR(ISERROR(H3); ISBLANK(H3)); I2; H3)
```

Na koniec moja tabela jest już uporządkowana. Ostatnim krokiem jest zmiana koloru tabeli, aby była bardziej czytelna.

	A	B	C	D	E	F	G	H
1	Transaction I	Item	Quantity	Price Per Unit	Total Spent	Payment	Location	Transaction Date
2	TXN_1961373	Coffee	2	2	4	Credit Card	Takeaway	2023-09-08
3	TXN_4977031	Cake	4	3	12	Cash	In-store	2023-05-16
4	TXN_4271903	Cookie	4	1	4	Credit Card	In-store	2023-07-19
5	TXN_7034554	Salad	2	5	10	Cash	In-store	2023-04-27
6	TXN_3160411	Coffee	2	2	4	Digital Wallet	In-store	2023-06-11
7	TXN_2602893	Smoothie	5	4	20	Credit Card	Takeaway	2023-03-31
8	TXN_4433211	UNKNOWN	3	3	9	Online	Takeaway	2023-10-06
9	TXN_6699534	Sandwich	4	4	16	Cash	In-store	2023-10-28
10	TXN_4717867	UNKNOWN	5	3	15	Online	Takeaway	2023-07-28
11	TXN_2064365	Sandwich	5	4	20	Card	In-store	2023-12-31
12	TXN_2548360	Salad	5	5	25	Cash	Takeaway	2023-11-07
13	TXN_3051279	Sandwich	2	4	8	Credit Card	Takeaway	2023-11-07
14	TXN_7619095	Sandwich	2	4	8	Cash	In-store	2023-05-03
15	TXN_9437049	Cookie	5	1	5	Cash	Takeaway	2023-06-01